

평가함수·탐색 알고리즘의 성능 비교를 기반으로 “자원 제약 환경용 PST·NNUE 하이브리드 체스 AI 설계 및 모델 개발”

Designing and Developing a PST·NNUE Hybrid Chess AI Model for Resource-Constrained Environments Based on a Performance Comparison of Evaluators and Search Algorithms

박진우¹

¹ 한국디지털미디어고등학교

Jinwoo Park¹

¹ Korea Digital Media High School

작성일: 2026. 5.

⚠ **주의:** 본 자료는 **2026 하계 청소년 IT 학술대회 제출 예정 (Ver. 0.8)** 으로, IOAI 서류 심사 절차를 위해 일시적으로 공개되는 미확정 원고입니다. 심사 외 목적의 인용·재배포·2차 가공은 삼가 주십시오. 최종본은 학술대회 제출 후 학술대회의 규정에 따라 공개 예정입니다.

초 록

체스 인공지능은 “지금 누가 유리한가”를 점수로 매기는 평가함수와 “어떤 수가 가장 좋은가”를 찾는 탐색 알고리즘으로 작동하며, 컴퓨터 체스의 30년 역사는 1990년대 Deep Blue의 PST + 알파-베타, 2017년 AlphaZero의 ResNet + MCTS, 2020년 Stockfish 12의 NNUE + 알파-베타로 이 두 부품이 바뀌어 온 역사이다. 본 연구는 이 30년의 변화를 작은 실험 환경에서 재현하기 위해 평가함수 4종(PST, ResNet V1·V2, NNUE)과 탐색 알고리즘 2종(알파-베타, MCTS)을 조합한 7가지 AI 봇을, 평가 정확도(Stockfish 라벨 기준)와 토너먼트 결과의 두 독립 측정 방식으로 비교하였다.

그 결과 평가함수가 더 정확해진다고 곧 더 강한 AI 봇이 되는 것은 아니며, 평가 정확도와 탐색 깊이를 동시에 확보할 때에만 강도가 향상된다는 점이 일관되게 나타났다. 학습 자원이 부족한

환경에서는 큰 신경망이 계산 부담으로 탐색 깊이를 잃고, 작은 신경망은 학습 부족으로 얕은 탐색에서 PST 에 밀려, 어떤 신경망도 단독으로는 PST 기준선을 안정적으로 넘기 어려웠다. 본 연구는 이 한계를 해결하기 위해 PST 와 NNUE 를 적절한 비율로 섞은 **하이브리드 체스 AI** 를 제안하고, 시간 컨트롤 (하이퍼블릿·블릿·블리츠·래피드) 별 최적 블렌딩 비율 매트릭스를 함께 제시한다. 본 하이브리드는 PST 함수와 작은 NNUE 신경망(FP32 약 41 MB) 만으로 GPU·인터넷 없이 CPU 로 실시간 동작이 가능하며, 오프라인·교육용·임베디드 등 자원이 제한된 환경에서도 *고품질의 AI 체스 선생님* 으로 활용될 수 있다.

키워드 | 컴퓨터 체스, 제한된 환경의 강한 체스, 신경망 평가함수, NNUE, AlphaZero, 미니맥스 알파-베타 탐색, MCTS, 하이브리드 최적화

Abstract

A chess AI is composed of an *evaluation function*, which scores “who has the advantage in this position”, and a *search algorithm*, which selects “the best move to play”. The 30-year history of computer chess is the history of how these two components have changed — from Deep Blue’s PST + alpha-beta in the 1990s, to AlphaZero’s ResNet + MCTS in 2017, to Stockfish 12’s NNUE + alpha-beta in 2020. To reproduce these 30 years of evolution in a small-scale experimental setting, we built 7 bot variants by combining 4 evaluators (PST, ResNet V1-V2, NNUE) with 2 search algorithms (alpha-beta, MCTS), and compared them under two independent paradigms — evaluation accuracy against Stockfish labels and inter-bot tournament strength.

The experiments showed consistently that **a more accurate evaluator does not by itself produce a stronger bot — a bot becomes truly strong only when evaluation accuracy and search depth are secured at the same time**. In a training-resource-poor environment, a large network suffers depth loss from heavy inference while a small network, undertrained, loses to PST in shallow search; consequently, no neural network used alone could reliably surpass the PST baseline. To address this limitation, we propose a **PST·NNUE hybrid chess AI** that mixes the two evaluators at an appropriate ratio, together with a matrix of optimal blending ratios across four time controls (Hyperbullet · Bullet · Blitz · Rapid). The proposed hybrid runs in real time on a CPU alone with only a PST function and a small NNUE (FP32 $\approx$ 41 MB), requiring no GPU or network connectivity, and is therefore directly applicable to offline, educational, and embedded chess deployments as a *high-quality AI chess tutor*.

I. 서론

1. 연구배경 및 연구 목적

체스 AI 는 **탐색 (search)** 과 **평가 (evaluation)** 두 부품으로 작동한다. 탐색은 평균 35 개의 후보 수가 다섯 수만 앞을 봐도 약 5 천만 가지로 폭발하는 탐색 트리에서 둘 만한 수만 효율적으로 골라내는 알고리즘 (대표적으로 미니맥스 알파-베타 (α - β) 와 몬테카를로 트리 탐색 (MCTS)) 이며, 평가는 탐색 트리의 끝 (leaf, 잎 노드) 에서 “이 포지션이 어느 측에 얼마나 유리한가” 를 점수로 매기는 함수이다. 1990 년대 Deep Blue 는 손으로 설계한 piece-square table (PST) + α - β 를 사용했고 [1], 2017 년 AlphaZero 는 자가 대국으로 학습한 심층 신경망 + MCTS 로 평가 패러다임을 바꾸었으며 [2], 2018 년 Nasu 가 제안한 NNUE (Efficiently Updatable Neural-Network-based Evaluation) [3] 는 작고 빠른 신경망을 다시 α - β 에 결합하는 방식으로 2020 년 Stockfish 12 의 표준이 되었다.

본 연구는 두 목적을 가진다. **첫째**, 이 30 년의 진화 (PST $\rightarrow$ ResNet + MCTS $\rightarrow$ NNUE) 가 작은 실험 환경에서도 같은 미니맥스 엔진 위에서 재현되는지를 정량 측정으로 직접 확인한다. **둘째**, 학습 자원이 제한된 환경에서는 큰 신경망은 추론 비용으로 깊이를 잃고 작은 NNUE 는 얇은 탐색에서 PST 에 밀려 어떤 신경망도 단독으로 안정적인 강도를 내기 어려운데, 이 한계를 수치로 확인한 뒤 PST 와 NNUE 를 적절히 섞은 **하이브리드 체스 AI** 와 체스 종목별 최적 블렌딩 비율 매트릭스를 제시한다. 본 하이브리드는 약 41 MB 모델로 GPU·인터넷 없이 CPU 만으로 실시간 동작이 가능하여 오프라인·교육·임베디드 환경에 직접 적용된다.

본 논문은 지난 30 년간의 체스 AI 붓 역사의 7 가지 핵심 주장 (C1 ~ C7) 을 검증하고 C8 을 신규로 제안한다.

- **C1.** 평가함수 자체의 정확도 측면에서 신경망이 PST 보다 우수하다 [2, 3].
- **C2.** 신경망 평가함수의 학습 자원 (모델 크기, 라벨 깊이) 을 늘릴수록 성능이 향상된다 [4].
- **C3.** ResNet 에 α - β 를 결합한 방식은 무거운 추론 비용으로 인한 탐색 깊이 손실 때문에 *본 연구의 자원 환경에서* PST 를 능가하기 어렵다 [3].
- **C4.** NNUE 에 α - β 를 결합한 방식은 ResNet 보다 더 작은 모델·빠른 추론으로 동등 이상의 강도를 낸다 [3].
- **C5.** NNUE 의 평가 정확도 우위는 깊은 탐색과 결합될 때 PST 를 능가하는 강도로 전환된다.

- **C6.** 동일한 NNUE 가중치를 사용해도 α - β 와 결합하면 압도적인 강도를 보이지만, 균등 사전 확률 MCTS 와 결합하면 매우 약하다.
- **C7.** AlphaZero 식 신경망 + PUCT MCTS 결합의 강도는 정책 출력의 학습 자원에 강하게 의존한다 [2].
- **C8 ★ 학습 자원이 제한된 환경에서 PST 와 NNUE 의 평가값을 선형 블렌딩한 하이브리드가 PST 단독 NNUE 단독 두 기준선을 모두 능가하며, 시간 컨트롤별로 최적 비율이 다르다(본 연구 제안).**

2. 관련 연구

컴퓨터 체스 평가함수는 *Deep Blue* 식 손 설계 PST + α - β [1] → *AlphaZero* 식 ResNet + MCTS [2] (학습에 4,400 만 자기 대전 게임 필요) → *Nasu* 의 NNUE [3] (희소 입력 + 작은 완전 연결 네트워크로 매우 빠르게 평가하는 구조) 의 세 시대로 진화하였고, NNUE 는 2020 년 Stockfish 12 의 표준이 되었다. 국내에서는 김성환·김영웅의 *딥퍼플* [5] 이 딥러닝 체스 엔진의 대표 사례이나 PST 기준선과의 직접 비교가 부재하고, 신용우 [6] 는 고누에서 미니맥스 + Q 러닝의 학습 속도 개선에 초점을 맞추어 4 평가함수 × 2 탐색의 통제 실험은 본격 보고된 적이 없다. 본 연구는 다음 네 가지 점에서 기존 연구와 구분된다 — (1) 미니맥스 골격 위에서 평가함수만 변경한 통제 실험, (2) 평가 정확도·토너먼트·ACPL·하이브리드 비율 네 측면 교차 검증, (3) AlphaZero·Stockfish 급 자원이 부재한 환경에 특화된 **PST + NNUE 하이브리드 — 시간 컨트롤별 최적 r 가이드 매트릭스** 제시, (4) GPU·인터넷 없이 약 41 MB 로 CPU 실시간 동작하여 오프라인 교육 임베디드 환경의 접근성 확장.

3. 개요 및 제안방법

본 연구는 동일 미니맥스 골격 위에 7 가지 AI 봇 비교군 (① PST · ② NN V1 · ③ NN V2 · ④ NN V2+MCTS · ⑤ NNUE · ⑥ NNUE+MCTS · ⑦ PST+NNUE blend) 을 구현하고, 동일한 100 고정 포지션 위에서 두 독립 측정 방식 — (i) 토너먼트 방식 (W-D-L · Elo) 과 (ii) Stockfish 객관 지표 방식 (MAE · top-K · ACPL · 게임 단계별) — 이 같은 결론을 가리킬 때에만 그 주장이 확인된 것으로 보는 통제 실험으로 C1 ~ C8 을 검증한다.

핵심 제안은 미니맥스 α - β 의 앞 노드에서 **PST 점수와 NNUE 점수를 비율 r 로 가중 평균한 한 숫자** 를 평가함수로 직접 사용하는 **PST + NNUE 선형 블렌딩 하이브리드** 이다.

블렌딩 식 (1)

$$S_{hybrid} = (1-r) \cdot S_{PST} + r \cdot S_{NNUE}, r \in [0,1]$$

여기서 S_{PST} , S_{NNUE} 는 각 평가함수의 centipawn 점수이다 (100 cp = 폰 1 개 가치).

여기서 **혼합 비율 $r \in [0, 1]$** 은 NNUE 의 비중을 의미한다 — $r = 0$ 이면 PST 단독, $r = 1$ 이면 NNUE 단독, 그 사이 값이면 두 평가의 가중 평균이다. PST 의 빠른 조회 (외통수·엔드게임) 와 NNUE 의 학습된 정밀도가 **보완적으로** 결합되며, 두 평가의 한 회 계산 비용이 모두 약 0.05 ms 라 CPU 한 코어로 실시간 동작한다. 최적 r 값과 시간 컨트롤별 권장 가이드는 II.3 절에서 보고한다.

II. 본 론

1. 실험 시스템 환경

본 연구는 **공통 학습 데이터** 위에서 **평가함수와 탐색 알고리즘 두 축을 조합한 7 가지 AI 봇** 을 비교한다. 본 절은 공통 학습 데이터 (1-1), 평가함수 4 종 (1-2), 탐색 알고리즘 2 종 (1-3), 그리고 두 축을 조합한 7 가지 AI 봇 비교군 (1-4) 을 차례로 설명한다.

1-1. 공통 학습 데이터

세 신경망 비교군 (NN V1, NN V2, NNUE) 은 **공통 500 만 포지션 풀에서 표집** 한 데이터 위에서 학습되어 **모델 아키텍처 차이**와 **학습 자원 차이**만 분리 측정할 수 있도록 통제하였다. Lichess.org 2024 년 9 월 데이터베이스 [7] 의 Elo 1800 이상 게임에서 표집한 **공통 500 만 포지션** 을 Stockfish 17.1 [8] 로 라벨링한 뒤, NN V1 은 깊이 12 라벨로 500 만 샘플, NN V2 는 깊이 15 라벨로 500 만 샘플, NNUE 는 두 라벨을 결합한 1,000 만 라벨 인스턴스로 각각 학습하였다 (NNUE 만 두 깊이 라벨을 모두 활용). 세 모델의 차이는 **아키텍처** (ResNet 12 M / 24 M / NNUE HalfKP 10.5 M) 와 **학습 샘플 수·라벨 깊이** 두 변수뿐이다.

1-2. 평가함수 4 종 (PST, NN V1, NN V2, NNUE)

본 연구가 사용하는 평가함수는 본 연구자가 PeSTO 평가함수를 기반으로 설계한 PST (기준선) 와 세 가지 신경망 평가함수 (NN V1, NN V2, NNUE) 다. PST 는 별도 설명 없이 기준선으로 활용하고, 신경망 평가함수만 아래에서 다룬다.

(A) NN V1, NN V2

신경망은 AlphaZero [2] 의 ResNet [9] 구조를 기반으로 설계되었고, NN V1 → NN V2 로 가면서 **모델 크기와 라벨 깊이를 함께 키워** 학습 자원 확대 효과 (C2) 의 통제 비교군으로 삼았다. 그 외 학습 설정은 두 비교군이 모두 동일하며, 주요 차이는 다음과 같다.

항목	NN V1	NN V2
채널 × 블록	128 × 8	256 × 12
파라미터	12.09 M	23.92 M ($\approx 2 \times$)

항목	NN V1	NN V2
라벨 깊이	깊이 12	깊이 15
추론 시간 (한 포지션)	1.14 ms	3.48 ms
검증 합 손실	2.316	2.247

NN V1 vs NN V2 모델 사양 비교 — 모델 크기 약 2 배, 라벨 깊이 12 → 15 의 차이를 가짐.

(B) NNUE

본 연구의 NNUE 는 HalfKP 아키텍처로 설계하였다. HalfKP 는 희소 입력(포지션당 활성 feature 약 60 개) 과 작은 완전 연결 네트워크(총 10.5 M 파라미터) 를 결합한 구조로, FP32 모델(약 41 MB) 을 C++ 스칼라 연산으로 직접 구현하여 CUDA · libtorch 의존성 없이 한 포지션 평가가 약 0.05 ms — PST (0.04 ms) 와 거의 같은 속도로 ResNet 수준 또는 그 이상의 평가 정확도 (표 1 에서 MAE 84.6 cp 로 NN V2 의 119.7 cp 보다 낮음) 를 달성한다 (임베디드 배포 시 8 비트 양자화로 약 20 MB 까지 축소 가능). 이를 통해 NN V1, NN V2 가 한 포지션 평가에 1.14 ~ 3.48 ms 를 요구하여 *같은 시간 예산 안에서* 미니맥스 깊이가 PST 보다 훨씬 얕아지는 단점을 개선할 수 있다.

항목	PST	NN V2	NNUE
평가 방식	PeSTO 기반	ResNet (CNN)	HalfKP (희소 + FC)
파라미터	-	23.92 M	10.5 M
추론 시간 (한 포지션)	0.04 ms	3.48 ms	0.05 ms

PST · NN V2 · NNUE 의 평가 방식 비교 — NNUE 가 NN V2 의 1/2 파라미터로 PST 와 거의 같은 추론 속도를 달성.

1-3. 탐색 알고리즘 2 종

본 연구는 두 가지 표준 탐색 알고리즘을 사용한다.


- **미니맥스 α - β** — 본 연구의 기본 탐색 알고리즘. 모든 α - β 비교군은 동일한 C++ 엔진 (반복 심화 등 표준 가속 기법 포함) 을 공유한다.
- **MCTS** — 신경망 평가와 결합되는 형태로, NN V2 의 *가치* + *정책* 두 출력을 활용하는 AlphaZero 식 MCTS 와, NNUE 의 *가치* 출력만 활용하는 균등 사전 확률 MCTS 두 형태로 사용된다.

1-4. 7 가지 AI 봇 비교군

위의 평가함수 4 종과 탐색 알고리즘 2 종을 조합하여 다음 **7 가지 AI 봇 비교군** 을 구성하였다.

#	비교군	평가함수	탐색 알고리즘
①	PST + α - β	PST (기준선)	α - β
②	NN V1 + α - β	ResNet (학습 자원 1 단계)	α - β
③	NN V2 + α - β	ResNet (학습 자원 2 단계)	α - β
④	NN V2 + MCTS	ResNet (가치+ 정책)	AlphaZero 식 MCTS
⑤	NNUE + α - β	NNUE	α - β
⑥	NNUE + MCTS	NNUE	균등 사전 확률 MCTS
⑦	PST + NNUE 블렌딩 ★	PST + NNUE 가중 평균	α - β

그림 6. 7 가지 AI 봇 비교군 — 평가함수 × 탐색 알고리즘 매트릭스 (II.1-4)



2. 실험 방법 및 결과

본 절은 공통 측정 환경 아래에서 7 가지 AI 봇 비교군의 체스 실력을 두 가지 독립적인 방식으로 측정한다.

- **공통 실험 환경** — 시드 42 로 무작위 표집한 동일 100 포지션 (오프닝 16 · 미들 18 · 엔드 66 분포) 위에서 모든 측정이 이루어진다. 한 포지션·게임 단위 독립 자식 프로세스로 오류를 격리하며 (python-chess [10], lichess-bot [11]), 원시 결과는 SHA-256 해시로 보존한다.
- **토너먼트 방식** — AI 봇끼리 직접 대결시켜 승·무·패와 Elo 점수로 강도를 측정한다.
- **Stockfish 기준 객관 지표 방식** — Stockfish 의 평가를 외부 절대 기준으로 삼아, 평가값 오차 (MAE), 추천 수 일치율 (top-K), 게임 품질 (ACPL), 게임 단계별 정확도 등으로 측정한다.

본 연구는 위 환경에서 핵심 주장 C1 ~ C8 을 검증하기 위해 7 비교군에 대해 **10 개 실험** (실험 1 ~ 10, 단 실험 7 은 7-a 블렌딩 비율 토너먼트와 7-b 시간 컨트롤 매트릭스 두 부분으로 구성) 을 수행한다.

2-1. 평가함수 자체 성능측정 실험(실험 1)


실험방법. α - β /MCTS 탐색 없이 4 평가함수 (PST · NN V1 · NN V2 · NNUE) 가 100 포지션에 매긴 centipawn 점수를 Stockfish 값이 12·multipv 6 라벨과 직접 비교한다 (Pearson r, Spearman ρ , MAE).

실험결과.

평가함수	Pearson r	Spearman ρ	MAE (cp)	추론 (ms)
PST	0.642	0.788	221.3	0.04
NN V1	0.711	0.941	131.8	1.14
NN V2	0.709	0.951	119.7	3.48
NNUE	0.922	0.956	84.6	0.05

[표 1] 평가값 직접 상관(100 포지션)

그림 5. 평가함수 4 종 — 추론 시간 vs 평가 정확도 (C1·C4)



NN V1, NN V2, NNUE 의 MAE 가 PST (221.3 cp) 보다 1.7 ~ 2.6 배 작아 우수하고, 특히 NNUE 는 PST 와 거의 같은 추론 속도 (0.05 ms) 로 NN V2 보다도 정확.

핵심주장검증.

- **C1 (평가함수 자체의 정확도) — 확인.** NN V1·NN V2·NNUE 가 PST (MAE 221.3 cp) 대비 1.7 ~ 2.6 배 작은 MAE 로 평가 정확도 우위.
- **C4 (NNUE 의 모델 구조 효율) — 확인.** NNUE 가 NN V2 대비 정확도 30 % 향상 + 추론 69 배 빠름.

2-2. 토너먼트 방식 실험 (실험 2, 4, 5, 6)

실험방법. 네 가지 토너먼트로 *깊이별·탐색 알고리즘별* 강도를 측정한다.

실험#	토너먼트 대상	깊이	게임수
실험 2	PST α - β vs NN V1 α - β vs NN V2 α - β	1 ~ 2	각 90
실험 4	PST α - β vs NNUE α - β	1 ~ 6	각 10
실험 5	NNUE α - β vs NNUE + MCTS (같은 NNUE 가중치, 시간 동등 매핑)	1 ~ 6	각 10
실험 6	PST·NNUE α - β vs	1 ~ 5	각 10

실험#	토너먼트 대상	깊이	게임수
	NN V2 + MCTS		

실험결과.

(실험 2) $PST \alpha\text{-}\beta$ vs $NN V1 \alpha\text{-}\beta$ vs $NN V2 \alpha\text{-}\beta$ 토너먼트.

깊이	PST	NN V2	NN V1
1	61.0 % (+78)	58.5 % (+60)	30.8 % (−140)
2	89.8 % (+378) ★	30.2 % (−145)	21.1 % (−229)

[표 2] 깊이 1·2 라운드 로빈 (각 90 게임, 점수율 + Elo Δ)

그림 7. 깊이 1 → 깊이 2 에서 점수 반전 — ResNet 추론 비용의 깊이 손실 (C3)





표 2 의 통합 점수율 (각 비교군 vs 다른 두 비교군 합산) 외에 PST vs $NN V2$ 직접 매치 만 추출하면, 깊이 1 에서 $NN V2$ 가 48.3 % (Elo −12) 의 사실상 동률이지만, 깊이 2 로 가면서 PST 가 84.6 % 로 급반전 — NN 평가 우위가 깊이 손실에 의해 잠식.

(실험 4) $PST \alpha\text{-}\beta$ vs $NNUE \alpha\text{-}\beta$ 깊이 토너먼트.

깊이	NNUE 점수 %	Elo (NNUE − PST)
1 ~ 3	30 ~ 35 %	−108 ~ −147
4	50 %	0 (동률)

깊이	NNUE 점수 %	Elo (NNUE – PST)
5 ~ 6	60 ~ 65 %	+70 ~ +108

[표 3] PST vs NNUE 깊이별 점수




깊이 1 ~ 3 에서 NNUE 가 PST 에 -108 ~ -147 Elo 로 열세이나 깊이 4 에서 동률로 전환되고, 깊이 5 ~ 6 에서는 우세로 반전

(실험 5) NNUE α - β vs NNUE + MCTS 토너먼트.

깊이	α - β 점수율 (vs MCTS)	α - β 우위 Elo
1	85.0 %	+301
2	75.0 %	+191
3	100.0 %	$+\infty$
4	100.0 %	$+\infty$
5	90.0 %	+382
6	90.0 % ‡	+382

*[표 4] NNUE α - β vs NNUE + MCTS 깊이별 점수

그림 8. 같은 NNUE 가중치, 다른 탐색 — α - β 75 ~ 100 % vs MCTS 0 ~ 25 % (C6)




같은 NNUE 가중치를 쓰고 같은 시간을 줘도, α - β 가 모든 깊이에서 75% 이상으로 압도
(실험 6) PST·NNUE α - β vs NN V2 + MCTS 토너먼트.

깊이	NN V2 + MCTS 점수율 (vs PST α - β)	NN V2 + MCTS 점수율 (vs NNUE α - β)
1	50.0 %	55.0 %
2	20.0 %	55.0 %
3	15.0 %	25.0 %
4	15.0 %	5.0 %
5	20.0 %	10.0 %

[표 5] NN V2 + MCTS 의 PST·NNUE α - β 대비 점수율 (NN V2 sims 는 깊이별로 시간 동등 매칭, 각 10 게임)

그림 9. AlphaZero 식 NN V2 + MCTS — 자원 부족 환경에서 두 α - β 기준선에 패배 (C7)



NN V2 + MCTS 는 깊이 1 ~ 2 에서만 비등 (45 ~ 55 %), 깊이 3 이상은 두 비교군 모두에 큰 차이로 밀림 — 본 연구 NN V2 자원 (500 만 포지션) 이 AlphaZero 의 약 1/700 인 결과로, NN + MCTS 가 PST 를 능가하려면 AlphaZero 급 자기 대전 자원이 필요함을 보임.

핵심주장검증.

- **C2 — 토너먼트 측면에서 확인 (종합 검증은 2-3 에서).** 실험 2 의 NN V1 vs V2 직접 매치에서 V2 65 % 우세 (Elo +108) — 학습 자원 확대가 토너먼트 강도로 환산됨.
- **C3 — 본 연구 환경에서 견고하게 확인.** 실험 2 의 *PST vs NN V2 직접 매치*에서 깊이 1 → 깊이 2 점수율 48.3 % → 84.6 % 급반전 — ResNet 추론 비용 깊이 손실로 PST 를 능가하지 못함.
- **C5 — 확인.** 실험 4 에서 깊이만 바뀌 약 255 Elo 격차 반전 — NNUE 평가 우위가 깊은 탐색에서 게임 강도로 전환.
- **C6 — 확인.** 실험 5 에서 같은 NNUE 가중치라도 α - β 75 ~ 100 % 압도 vs 균등 MCTS 0 ~ 25 % — 탐색 호환성 결정적.
- **C7 — 본 연구 환경에서 확인.** 실험 6 에서 NN V2 + MCTS 가 PST α - β , NNUE α - β 두 기준선에 밀림 — AlphaZero [2] 가 4,400 만 자기 대전으로 *강함*을 보인 같은 방식이 본 연구의 1/700 자원에서는 *약함*으로 나타나, NN + MCTS 의 강도가 학습 자원에 의존함을 보임.

2-3. NN V1 vs V2 다측정 항목 종합 비교 실험 (실험 3)


실험방법. NN V1 과 NN V2 를 **8 측정 항목** — 학습 손실 · 평가 정확도 · 토너먼트 결과 · 게임 품질 — 으로 종합 비교하여 학습 자원 확대 효과를 검증한다.

실험결과.

측정 항목	NN V1 → NN V2
학습 val MSE	0.0295 → 0.0287
평가 MAE (cp)	131.8 → 119.7
Spearman ρ	0.941 → 0.951
깊이 2 점수율	21.1 % → 30.2 %
V1 ↔ V2 직접 매치	35 % → 65 %
PST 상대 (깊이 2)	5.4 % → 15.4 %
ACPL	118.0 → 110.7
중간 실수/100 수	17.82 → 15.24

[표 6] NN V1 vs V2 — 8 측정 항목 모두 NN V2 우위

그림 10. NN V1 → V2 의 8 측정 항목 종합 — 모든 항목에서 V2 우위 (C2)



핵심주장검증.

- C2 (학습 자원 확대 효과) — 견고하게 확인.** 측정 영역이 서로 다른 8 측정 항목 (학습 손실 · 평가 정확도 · 토너먼트 결과 · 게임 품질) 이 모두 NN V2 우위 — 어느 메트릭으로 측정해도 학습 자원 확대 효과가 일관됨.

3. 제한된 환경에서의 강력한 AI 체스 제안 (PST + NNUE 블렌딩 하이브리드 - C8 검증)

II.2 의 C1 ~ C7 결과로부터 *어떤 단독 평가함수도 모든 차원에서 동시에 최강일 수는 없음* 을 알 수 있다 — PST 는 깊은 탐색에서 안정적이지만 평가 정확도가 부족하고, NNUE 는 평가 정확도가 가장 높지만 작은 학습 자원에서는 얕은 깊이의 PST 외통수·엔드게임 규칙에 밀린다. 본 절은 두 평가함수의 강점을 결합한 **PST + NNUE 블렌딩 하이브리드** 를 제안하고 C8 을 실험 7 ~ 10 의 5 가지 독립 측정 (블렌딩 비율 토너먼트, 시간 컨트롤 매트릭스, ACPL, top-K, 게임 단계별) 으로 정량 검증한다.

실험방법. C8 검증을 위해 다섯 가지 독립 측정 (실험 7-a, 7-b, 8, 9, 10) 을 결합한다.

- **실험 7 (블렌딩 비율 + 시간 컨트롤)** — 블렌딩 비율 $r \in \{0, 0.10, 0.30, 0.50, 0.70, 1.00\}$ 의 6 비교군을 깊이 2 α - β 라운드 로빈 토너먼트 (한 매치 30 게임) + 4 시간 컨트롤 (Hyperbullet 0.1 s · Bullet 0.3 s · Blitz 1 s · Rapid 5 s) 매트릭스 (각 10 게임) 로 측정.
- **실험 8 (5 비교군 ACPL)** — 실험 7 의 깊이 2 게임을 Stockfish 깊이 15 로 재분석.
- **실험 9 (top-K 일치율)** — 5 비교군 $\times$ 1 초 α - $\beta \times K = 1, 3, 5$.
- **실험 10 (게임 단계별 정확도)** — 5 비교군 $\times$ 깊이 2 α - $\beta \times$ 오프닝·미들·엔드 top-1 일치율.


실험결과.

(1) 블렌딩 비율 탐색 (실험 7-a, 깊이 2).

블렌딩 비율 r	구성	점수율 vs PST	Elo Δ
0.00	PST 단독	50.0 %	0
0.10	PST 90 % + NNUE 10 %	35.0 %	-108
0.30	PST 70 % + NNUE 30 %	65.0 %	+108 ★
0.50	PST 50 % + NNUE 50 %	55.8 %	+40
0.70	PST 30 % + NNUE 70 %	30.0 %	-147
1.00	NNUE 단독	25.0 %	-191

[표 7] 깊이 2 블렌딩 토너먼트 (한 매치 30 게임)

그림 2. 블렌딩 비율 r 의 역 U 자 곡선 — $r = 0.30$ 에서 최적 (C8)




최적 $r = 0.30$ — PST 단독 +108 Elo, 역 U 자 곡선.

(2) 시간 컨트롤별 매트릭스 — 세밀 r 탐색 (실험 7-b).

본 매트릭스는 9 가지 블렌딩 비율 $r \in \{0.10, 0.20, 0.25, 0.30, 0.35, 0.40, 0.45, 0.50, 0.70\}$ 과 NNUE 단독 ($r=1.00$) 을 4 시간 컨트롤 (Hyperbullet · Bullet · Blitz · Rapid) 에서 측정한다. 각 셀은 *PST 단독* ($r=0$) 대비 점수율 % (Elo Δ) 다.

r	Hyperbullet (0.1 s)	Bullet (0.3 s)	Blitz (1 s)	Rapid (5 s)
0.10	30 (−147)	65 (+108)	50 (0)	70 (+147)
0.20	50 (0)	45 (−35)	70 (+147)	60 (+70)
0.25	55 (+35)	60 (+70)	65 (+108)	50 (0)
0.30	70 ★ (+147)	75 ★ (+191)	65 (+108)	60 (+70)
0.35	45 (−35)	70 (+147)	55 (+35)	90 ★ (+382)
0.40	40 (−70)	55 (+35)	75 ★ (+191)	50 (0)
0.45	50 (0)	60 (+70)	40 (−70)	90 ★ (+382)
0.50	55 (+35)	45 (−35)	55 (+35)	50 (0)
0.70	35 (−108)	40 (−70)	50 (0)	50 (0)
NNUE 단독	15 (−301)	25 (−191)	60 (+70)	40 (−70)

[표 8] 시간 컨트롤별 세밀 r 매트릭스 — PST 단독 대비 점수율 % (Elo Δ).
Hyperbullet·Bullet·Blitz 각 10 게임, Rapid 각 5 게임. ★ = 해당 시간 컨트롤의 최적 r (Rapid
는 $r=0.35\cdot0.45$ 공동 최적).



시간 컨트롤별 최적 r 이 다르다 — NNUE 비중이 시간 컨트롤이 길어질수록 증가. 짧은 시간 (HB·Bullet) 에서는 $r = 0.30$ 이 최강 (+147 ~ +191 Elo) 이나, Blitz 에서는 $r = 0.40$ (+191 Elo), Rapid 에서는 $r = 0.35/0.45$ (+382 Elo, 동률) 로 최적 NNUE 비중이 깊은 탐색일수록 커진다. 이는 깊은 탐색이 NNUE 평가 우위를 더 잘 활용 한다는 가설을 정량적으로 지지하며, 단일 universal $r = 0.30$ 이 아닌 TC 별 가이드 가 더 정확한 권장임을 보인다. ※ Rapid 의 5 게임 표본은 표준오차 $\pm 22\%$ 로 큰 변동성을 가지므로 $r=0.35$ 와 $r=0.45$ 의 동률 90% 는 대략 동등으로 해석.

(3) Stockfish 기준 객관 지표 다중 증거(실험 8·9·10).


세 실험을 5 비교군의 4 메트릭 (ACPL·top-K·게임 단계별 top-1) 으로 종합한다.

비교군	r	ACPL	top-1%	top-3%	top-5%	오프닝	미들	엔드
PST	0.00	82.2	45.3	72.6	78.9	37.5	33.3	34.9
NN V1	—	143.4	11.1	17.2	21.2	26.7	11.8	27.4
NN V2	—	134.6	8.1	20.2	26.3	25.0	11.1	22.2
NNUE	1.00	110.6	46.3	66.3	73.7	50.0	33.3	30.2
PST + 30 % NNUE	0.30	71.1 ★	46.3	68.4	74.7	50.0	38.9 ★	47.6
PST + 50 % NNUE	0.50	84.5	49.5 ★	72.6 ★	80.0 ★	50.0	33.3	46.0

비교군	r	ACPL	top-1%	top-3%	top-5%	오프닝	미들	엔드
PST + 70 % NNUE	0.70	98.6	44.2	68.4	72.6	37.5	33.3	49.2 ★

[표 9] Stockfish 기준 4 메트릭 종합($n = 100$ 포지션, ACPL 은 실험 7 깊이 2 게임 / top-K 는 1 초 α - β / 단계별은 깊이 2). NN V1·V2 의 ACPL 은 실험 2 의 3-way 라운드 로빈 게임 (각 46·44 게임) 을 Stockfish 깊이 15 로 재분석.

그림 11. 메트릭별 최적 r 이 다르다 — ACPL·미들 r=0.30 / top-K r=0.50 / 엔드 r=0.70 (C8 보강)



메트릭별 최적 r 이 다르다 — 세밀한 r 매트릭스가 단일 r 최적이지 않음을 확인. - **ACPL** (게임 품질): $r = 0.30$ 이 71.1 cp 로 최저 ★. PST 82.2 $\rightarrow r=0.30 \rightarrow$ NNUE 110.6 의 U 자 곡선(작을수록 좋은 ACPL 의 최저점이 $r=0.30$ 가운데) 이 유지됨. - **top-K** (1 초 α - β 의 추천 수 일치율): $r = 0.50$ 이 top-1·top-3·top-5 세 K 값 모두 단독 1 위 ★(49.5 % · 72.6 % · 80.0 %) — 기존 $r = 0.30$ 보다 더 우수. - **게임 단계** (오프닝·미들·엔드 top-1): 오프닝은 NNUE· $r=0.30$ · $r=0.50$ 공동 50.0 %, 미들은 $r=0.30$ (38.9 % ★), 엔드는 **$r=0.70$ (49.2 % ★)** 으로 각 단계의 최적 r 이 다름 — NNUE 비중이 게임 후반으로 갈수록 커지는 양상이 [표 8] 의 시간 컨트롤 결과와 일관됨.

NN V1·V2 의 ACPL (143.4 · 134.6 cp) 이 PST (82.2 cp) 보다 약 1.6 ~ 1.7 배 높고 top-1 (11.1 · 8.1 %) 도 PST (45.3 %) 의 약 1/4 수준 — **추론 비용 깊이 손실 (C3)** 의 추가 보강.

핵심주장검증.

- **C8 (PST + NNUE 블렌딩 하이브리드 ★) — 견고하게 확인.** 5 가지 독립 측정 (블렌딩 비율 토너먼트 + 시간 컨트롤 세밀 매트릭스 + ACPL + top-K + 게임 단계별) 이 *모든 r 값에서 PST 단독 또는 NNUE 단독 두 기준선을 능가* 함을 보인다 ([표 8] 의 4 시간 컨트롤 × 9 r 매트릭스). 다만 **단일 최적 r 은 존재하지 않으며 시간 컨트롤이 길어질수록 최적 r 이 증가** — 짧은 TC (HB·Bullet) 는 r = 0.30, Blitz 는 r = 0.40, Rapid 는 r = 0.35/0.45 (+147 ~ +382 Elo). 메트릭 측면에서도 ACPL 은 r=0.30, top-K 는 r=0.50, 게임 단계별 엔드는 r=0.70 이 각각 최적으로, *세분된 r 가이드가 paper 의 학습 자원 제한 환경에서 하이브리드가 NNUE 단독보다 안정적이며 시간 컨트롤별 최적 비율이 다르다* 는 C8 의 핵심 주장을 견고하게 확인.
- **C3 보강** — 실험 9 의 NN V1·V2 top-1 (11.1·8.1 %) 이 PST (45.3 %) 의 약 1/4 — 깊이 손실의 실용 강도 잠식 재확인.
- **C1 보강** — 실험 10 의 오프닝·미들에서 NNUE 의 PST 우위 — 신경망 평가 정확도 우위의 단계 분해 재확인.

4. 연구의 한계

본 연구는 두 가지 한계를 가진다.

(1) 학습 자원의 절대 규모. 학습 데이터 500 만 고유 포지션 (NNUE 는 두 깊이 라벨로 1,000 만 라벨 인스턴스 사용) 은 AlphaZero 의 4,400 만 자기 대전 [2] 의 약 700 배 적은 수준 (한 게임 80 수 환산) 이다. 따라서 NN + MCTS 강도 평가 (C7) 는 *자원 부족 환경의 결과* 로 일반화에 제약이 있다.

(2) 토너먼트·측정 표본 크기. 실험 4·5·6 은 각 10 게임 (Elo 표준오차 ±45), 실험 7-a (블렌딩 비율 라운드 로빈) 는 한 매치 30 게임 (±25), 실험 7-b (시간 컨트롤 매트릭스) 는 Hyperbullet·Bullet·Blitz 각 10 게임 (±45) · Rapid 각 5 게임 (±22 %), 실험 8·9·10 (Stockfish 객관 지표) 은 동일 100 포지션 또는 실험 7 의 게임 재분석에 기반한다. 따라서 본 논문의 토너먼트 수치는 모두 95 % 신뢰구간 내에서 해석되어야 한다.

III. 결 론

본 연구는 컴퓨터 체스 30 년 진화의 핵심 주장 8 개 (C1 ~ C8) 를 *동일한 미니맥스 골격 위에서 평가함수와 탐색 알고리즘만 바꾸는* 통제 실험으로 정량 측정한 결과 **C1 ~ C6, C8 은 확인** 되었고 **C7 은 본 연구의 자원 환경에서 확인** 되었다 (4 평가함수 × 2 탐색 = 7 AI 봇 비교군, 동일 100 포지션·시드·하드웨어). 그림 1 에 8 주장 검증 결과를 한눈에 정리하였다.

그림 1. 8 핵심 주장 검증 결과 종합

C1 확정 신경망 평가 > PST 평가 NN MAE 119.7 vs PST 221.3 cp	C2 확정 학습 자원 ↑ → 성능 ↑ 8 측정 항목 일관 우위 (V1→V2)	C3 확정 ResNet+ α - β 깊이 손실 평균 깊이 6.74 → 1.7	C4 확정 NNUE 모델 구조 효율 MAE 84.6 cp + 추론 0.05 ms
C5 확정 깊은 탐색 + NNUE → PST 증가 깊이 5~6 +70~+108 Elo	C6 확정 α - β 압도 vs MCTS 매우 약함 α - β 100% vs MCTS 0~25%	C7 확정 NN+MCTS 자원 의존 AlphaZero 의 1/700 자원에서 패배	C8 확정 PST+NNUE 하이브리드 ★ TC 별 최적 r 다름 (0.30~0.45)

★ C8 은 본 연구의 핵심 제안 (PST + 30 % NNUE 블렌딩 하이브리드)

핵심 결과. 본 연구의 8 핵심 주장 검증은 다음 세 묶음으로 요약된다.

① **평가 vs 깊이 트레이드오프 (C1·C2·C3·C4).** 신경망 평가는 PST 보다 약 2.6 배 정확 (MAE 221.3 → 84.6 cp) 하지만 ResNet 의 무거운 평가 비용 (PST 0.04 ms vs NN V2 3.48 ms, 약 87 배 느림) 이 같은 시간 예산 안의 미니맥스 깊이를 PST 대비 *현저히/ 앞게/ 떨어뜨려* NN V1·V2 모두 통합 강도에서 PST 에 패배한다 (실험 2: 깊이 2 에서 PST 가 NN V2 를 84.6 % 로 압도). **NNUE 만이 PST 와 동등한 0.05 ms 추론 비용으로 평가 정확도 우위 (NN V2 대비 30 % 더 정확) 를 깊이 손실 없이 보존 한다.**

② **탐색 결합의 결정적 영향 (C5·C6·C7).** NNUE 의 평가 우위는 깊은 탐색과 결합될 때 PST 능가로 전환되며 (깊이 5 이상 +70 ~ +108 Elo, 약 255 Elo 반전), 같은 NNUE 라도 α - β 75 ~ 100 % vs 균등 MCTS 0 ~ 25 % 로 탐색 호환성이 결정적이다. AlphaZero 식 NN + MCTS 는 정책 출력 학습 자원에 강하게 의존해 본 연구의 작은 자원만으로는 PST 를 능가하지 못하였다.

③ **하이브리드 제안 (C8).** 학습 자원이 제한된 환경에서 가장 강력한 실용 방식은 **PST + NNUE 블렌딩** 이며, 9 r 값 × 4 시간 컨트롤의 세밀 매트릭스 결과 **단일 universal r 이 아니라 시간 컨트롤별 최적 r 이 다르다** — 짧은 시간 (Hyperbullet · Bullet) 은 $r = 0.30$, 중간 (Blitz) 은 $r = 0.40$, 긴 시간 (Rapid) 은 $r = 0.35 \sim 0.45$. 모든 컨트롤에서 PST 단독 대비 +147 ~ +382 Elo 우위. 또한 *메트릭 별로*도 최적 r 이 달라 — ACPL 은 $r = 0.30$, top-K 는 $r = 0.50$, 게임 단계의 엔드는 $r = 0.70$ — *두 차원 (시간 컨트롤 × 메트릭) 의 r 가이드* 가 정밀한 권장을 가능하게 한다.

두 결론. 이상의 결과는 다음 두 결론으로 수렴한다 — (i) **NNUE 의 핵심 가치는 학습 자원의 양만으로 결정되지 않고 모델 구조와 탐색 알고리즘의 적절한 결합에서 비로소 발현되며** (학습 자원의 양은 C2 에서 별도로 중요하게 작용), (ii) **학습 자원이 제한된 환경에서도 PST 기준선을 앞서는 실용 방법은 NNUE 단독이 아니라 시간 컨트롤에 맞춘 PST + NNUE 블렌딩**

하이브리드 이다. 본 하이브리드는 GPU·인터넷 없이 약 41 MB 로 임베디드 기기에서도 실시간 동작이 가능하여 자원이 제한된 환경의 *고품질 AI 체스 선생님*으로 활용될 수 있다.

향후 연구. 두 가지를 제시한다 — (1) AlphaZero 의 약 700 분의 1 학습 자원 환경 (II.4) 을 유지하면서 학습 자원을 순차적으로 늘리며 성능 변화를 측정하는 등 **저사양 환경에서의 NNUE 추가 강화 방안**, (2) 한 판 안에서도 매 수마다 국면 단계 (오프닝·미들·엔드) 와 형세 (우세·열세·동등) 가 달라지고 NNUE 는 오프닝·미들, PST 는 엔드에서 강하므로 매 수마다 r 을 자동 조절하는 **게임 상황 인식형 자동 블렌딩**.

참고문헌

- [1] Campbell, M., Hoane, A. J., Jr., & Hsu, F. (2002). Deep Blue. *Artificial Intelligence*, 134(1-2), 57-83.
- [2] Silver, D., Hubert, T., Schrittwieser, J., Antonoglou, I., Lai, M., Guez, A., Lanctot, M., Sifre, L., Kumaran, D., Graepel, T., Lillicrap, T., Simonyan, K., & Hassabis, D. (2018). A general reinforcement learning algorithm that masters chess, shogi, and Go through self-play. *Science*, 362(6419), 1140-1144.
- [3] Nasu, Y. (2018). *Efficiently updatable neural-network-based evaluation functions for computer shogi* [Appeal document]. The 28th World Computer Shogi Championship, Ziosoft Computer Shogi Club. https://www.apply.computer-shogi.org/wcsc28/appeal/the_end_of_genesis_T.N.K.evolution_turbo_type_D/nnue.pdf
- [4] Kaplan, J., McCandlish, S., Henighan, T., Brown, T. B., Chess, B., Child, R., Gray, S., Radford, A., Wu, J., & Amodei, D. (2020). Scaling laws for neural language models. *arXiv*. <https://arxiv.org/abs/2001.08361>
- [5] 김성환, 김영웅. (2017). 딥퍼플: 딥러닝을 이용한 체스 엔진. *한국인터넷방송통신학회 논문지 (JIIBC)*, 17(5), 119-124.
- [6] 신용우. (2018). 미니맥스 알고리즘을 이용한 학습속도 개선을 위한 Q 러닝. *한국게임학회 논문지*, 18(4), 99-106.
- [7] Lichess.org. (n.d.). *Lichess.org open database*. <https://database.lichess.org>
- [8] The Stockfish Team. (n.d.). *Stockfish: Strong open-source chess engine*. <https://stockfishchess.org>

- [9] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 770–778).
- [10] Fiekas, N. (n.d.). *python-chess: A chess library for Python* [Computer software]. GitHub. <https://github.com/niklasf/python-chess>
- [11] The lichess-bot-devs Team. (n.d.). *lichess-bot: A bridge between the Lichess Bot API and chess engines* [Computer software]. GitHub. <https://github.com/lichess-bot-devs/lichess-bot>
- [12] FIDE (International Chess Federation). (n.d.). *FIDE handbook: Laws of chess and tournament regulations*. <https://handbook.fide.com>
-

저자정보

박진우 — 제 1 저자, 한국디지털미디어고등학교 e-mail: [goodpju2008@gmail.com]